

档案智能编研的内涵阐释与模式构建研究

李 甜^{1,2} 关陟昊^{1,2} 寇远涛^{1,2}

(1 中国农业科学院农业信息研究所 北京 100081; 2 国家新闻出版署农业融合出版知识挖掘与知识服务重点实验室 北京 100081)

摘 要 档案编研具有挖掘和激活档案文化资源、打造档案文化精品、建设和弘扬档案文化的重要作用,是档案事业融入文化数字化战略和数字文化建设大潮的切入点和发力点之一。文章在梳理档案编研发展历程和现实需求的基础上,围绕解决档案编研痛点,从主体、客体、手段和成果四个方面分析档案智能编研的变化,总结出其机械化、去经验化、知识化的内涵特征和从劳动密集向机械密集、从以编为主向以研为主、从批量制作向个性定制转变的三大形式特征变化,并围绕资源层、数据层、知识层、技术层、功能层构建了档案智能编研模式,以指导档案智能编研实践。

关键词 档案智能编研; 编研模式; 智能操作; 智慧决策; 知识组织

DOI: 10.16065/j.cnki.issn1002-1620.2024.04.013

Research on Archives Intelligent Compilation: Definition Interpretation and Pattern Construction

LI Tian^{1,2}, GUAN Zhihao^{1,2}, KOU Yuantao^{1,2}

(1 Agricultural Information Institute of CAAS, Beijing 100081; 2 Key Laboratory of Knowledge Mining and Knowledge Services in Agricultural Converging Publishing, National Press and Publication Administration, Beijing 100081)

Abstract: Archives compilation plays an important role in excavating and activating archives cultural resources, creating exquisite works of archives culture, and constructing and carrying forward archives culture. And this is one of the entry points and strength points for the archives career to integrate into the cultural digitization strategy and the tide of digital cultural construction. Based on the review of the development history and practical needs of archives compilation, focusing on solving the pain points of archives compilation, this paper analyzed the changes of intelligent archives compilation from four aspects: subject, object, means and results. It summarized the connotation characteristics of mechanization, non-empirical and intellectualization, and the changes of three formal characteristics from labor intensive to machinery intensive, from compilation to research, and from batch production to individual customization. Then, this paper constructed the archives intelligent compilation mode around the resources layer, data layer, knowledge layer, technology layer and function layer, so as to guide the practice of archives intelligent compilation.

Key words: archives intelligent compilation; compilation pattern; intelligence operation; wisdom decision; knowledge organization

0 引言

2022年被称为国家文化数字化战略元年,文化数字化从“十二五”时期的工程项目上升为国家战略。2023年2月,中共中央、国务院印发的《数字中国建设整体布局规划》对数字文化建设作出顶层设计和战略安排。《“十四五”全国档案事业发展规划》要求加大档案资源开发力度,通过编研出版等方式,不断推出具有广泛影响力的档案文化精品。档案编研作为深入挖掘和激活档案文化资源、打造档案文化精品、建设和弘扬档案文化的基础工作,成为档案事业融入文化数字化战略和数字文化建设大潮的切入点和发力点之一。然而,档案编研现存的选题陈旧、编研周期长、编研力量薄弱、人工操作为主、主观决策等诸多痛点与卡点,导致编研效率低下、“编”多“研”少、精品少等问题,使档案编研面对文化建设大潮的历史契机和广阔舞台显得捉襟见肘。据此,本研究主要研究两个问题,一是何为档案智能编研,如何解决档案编研的痛点问题;二是档案智能编研如何实现,可构建怎样的编研模式。以为解决档案编研痛点与卡点问题提供理论参考与实践建议。

1 档案智能编研的发展背景

1.1 理论层面,档案编研进入智能编研阶段

我国档案编研研究围绕档案编研实践发展,呈现出明显的阶段特征,在总结前人研究的基础上,本研究认为档案编研研究存在三个主要阶段。

一是档案史料编纂阶段(20世纪80年代以前),以汇编历史档案为主,以曹喜琛、丁永奎为代表,主要对档案史料编纂的基础理论知识进行论述。^[1]

二是大编研阶段(20世纪80年代至90年代中期),这一阶段开始突破汇编历史档案的局限,有关科技档案编研的专著和论文问世,档案编研在主体、客体、范围等方面呈现扩展与增强趋势,时称“大编研”。^[2]

三是档案智能编研阶段(20世纪90年代后期至今),档案编研进一步突破选材范围和编研方式的局限,随着技术进步,在经过对档案编研基本问题(谁来编研、编研什么、为谁编研)的思考、对档案编研工作中存在的问题及其策略探讨后,“新环境下档案编研工作的创新发展”成为研究热点^[3],出现“数字编研”“数据化编研”“档案智能编研”等

理念,档案编研进入新的阶段。尤其是大数据和新一代人工智能技术出现后,本体构建、知识图谱、增强现实技术、可视化分析等大数据和人工智能技术被引入档案编研,沿着细粒度挖掘研究主题、运用可视化交互方式将编研产品予以展示的路径发展^{[4][5]},档案编研的数智化特征进一步增强,档案编研进入智能编研阶段。

进入智能编研阶段后,档案编研空间从“模拟态—数字态”的对象空间跃升至“数据态—知识态—价值态”的价值空间^[6],编研逻辑从材料管理向数据管理转变,编研方式从史料编研向信息编研转变。总体来说,档案编研在编研形态、编研空间、编研逻辑、编研方式等方面实现了全方位跃升,现有研究将其高度概括为“实现了从传统档案编研由单一、线性、封闭走向多维、关联、交互的发展”^[7](见表1)。

表1 档案编研发展阶段

编研阶段	主要特征	成果载体形态
传统编研阶段	单一、线性、封闭	纸本形态
大编研阶段	主体、客体、范围的扩展	以纸本形态为主,开始出现数字形态
档案智能编研阶段	多维、关联、交互	以数字形态为主

1.2 实践层面,内容级开发利用的需求驱动档案编研向纵深发展

进入知识经济时代后,用户对档案主题内容的需求凸显,呈现出细粒度化和语义化的发展趋势。随着大数据、人工智能等技术的演进,学科、领域之间的扩张和交叉融合加剧,多源、海量、异构的大数据带来“信息泛滥、知识匮乏”的困扰,用户的需求从信息资源简单汇集向内部精细化、语义化关联、挖掘与揭示转变,高效智能地从数据资源中挖掘和发现新知识和新规律的需求进一步提升,档案内容深加工利用的趋势不可逆转。用户不仅想知道关于特定主题/需求都有哪些相关的档案素材(即传统档案汇集),更关心有关档案记录中可供揭示和挖掘的规律或知识(隐含对档案内容进行加工、分析、组织等要求)。然而据统计,全国各地档案部门每年公开出版和内部编印的档案编研图书有七八百种,但大都采用汇编或摘编的形式,即把档案原件影印或重新排印并汇集在一起,供读者使用^[8],尚未有效回应上述趋势。这与用户渴求对档案内容进行重组加工,挖掘、发现、利用知识和规律的需求相悖,档案编研工作亟须实现内容级开发利用的有效推进。

另外,大数据、人工智能等数智技术也为档案

内容级开发利用需求的实现提供了技术可能性。尤其是知识图谱、深度学习等新一代人工智能技术,为多模态的档案内容分析、语义重组等提供了技术手段,在数据形式、资源描述、关系表达、资源聚集等方面发挥了重要作用。^[9]譬如,围绕档案数据,从档案数据化到数据化开发,利用人工智能(AI)、智能光学字符识别(OCR)和自然语言处理(NLP)等智慧化技术手段进行档案数据的关联、挖掘和分析^[10],将档案挖掘与开发从实体级深入内容级的数据层面与知识层面。在技术的助力下,档案开发利用层次从外部的形式特征,到粗粒度主题内容,再到细粒度知识内容,实现了从文件级到数据级再到知识单元级的不断深入与细化。档案编研也因此具备了由传统编研局限于档案资源的汇聚排序的浅层次发展^[11],向档案内容分析、重组、语义关联的深层次开发利用转变的现实可能性。在用户需求和科技赋能的双重推动下,档案智能编研向内容级开发利用发展。

2 档案智能编研的内涵阐释

档案编研进入智能编研阶段后,虽然在编研形态、空间、逻辑、方式等方面都有了明显进步,但仍存在一些痛点问题尚未有效解决,影响着档案编研的长足发展及其价值实现。操作层面,手段初级、效率低下,影响编研成果时效性。档案编研仍然大量

依靠人工操作,通过重复性、体力性劳动进行档案素材的搜集、摘选转录等工作,编研效率低下,编研周期长。组织层面,决策主观性强,影响编研成果科学性。档案编研的选题、选材、编研、利用等各流程主要依靠经验决策,主观性强,编研成效科学性和稳定性难以保证,出现选题陈旧、主观经验决策、编研力量薄弱等问题。结果层面,编研失衡,重“编”轻“研”。编研重心放在档案资源的编排层面,缺少对档案内容的重组与揭示,导致编研成果精品少,影响编研价值的发挥。围绕解决档案编研存在的痛点问题,本研究通过档案智能编研内涵阐释,对应说明档案智能编研如何解决上述痛点问题(见图1)。

2.1 档案智能编研的变化

档案智能编研是数智技术与档案开发利用深度融合应用的产物,档案智能编研尤为强调数字技术与智能技术在档案编研工作程序上的业务赋能,由人工编研为主走向半自动或自动化编研。^[12]现有的档案智能编研主要包括三个方面的内容:构建馆(室)内专题知识库、基于知识图谱技术编研、编研成果可视化。^[13]

2.1.1 编研主体从单一主体向联合主体转变

档案智能编研的发展,是不断打破单一编研主体限制的过程。档案编研进入智能阶段前,以档案馆(室)作为单一编研主体牵头档案编研工作为主,档案馆之间、档案馆与其他主体之间的交流协作较为稀少。以北京市为例,据调查,北京市各市属机关




图1 档案智能编研解决档案编研痛点思路图

和档案机构的编研成果,档案部门自编成果比例高达90.51%,与其他部门合编成果不足10%。^[14]这种单一主体的编研模式受限于馆藏数量、编研团队实力等因素的影响,越来越难以满足社会对编研的需求。随着档案编研向智能阶段迈进,发生了如下变化。一是单一主体的编研模式被打破,多个机构间共同合作开展档案编研工作成为发展的主流,并且合作的机构类型不断丰富,从图书馆、高校等文化科研类机构拓展至民间机构。如从1949年以来,广西壮族自治区档案馆就与机构和组织开展了合作,有官方层面的中央档案馆、广西壮族自治区民族宗教事务委员会、广西壮族自治区桂林图书馆等,也有民间组织如柳州客家联谊会以及柳州客家商会等。^[15]不同的编研主体之间开展合作,促进档案编研资源的共享、联合开发利用,有利于丰富档案编研的选题与选材,是实现档案智能编研的重要基础。二是编研团队逐渐吸纳其他领域的专业人士。如2016年南京市档案馆与南京市中山陵园管理局、孙中山纪念馆合作进行中山陵档案编研,后续还与南京江南丝綢文化博物馆、江宁织造博物馆等开展了合作,并吸纳业界大师作为技术顾问参与档案编研工作。^[16]不同领域专业人士参与档案编研工作,使编研团队构成更为科学合理,可以更好地满足档案智能编研所需的多样化专业素养,为档案智能编研的实现提供人才资源保障。

2.1.2 编研客体的范围与模态更加立体多元

档案智能编研的发展,是档案客体不断丰富升级的过程。档案编研进入智能阶段以前,档案编研客体以馆藏档案为主。馆藏档案的数量、类型、特色对档案编研的选题、成果形式等都有影响。档案智能编研客体的变化体现在空间和模态两个维度。一是空间维度从受限于馆藏范围到不受限。档案编研突破单一主体限制以后,不同机构间的合作加多加深,档案编研客体也从单一的馆藏范围向外拓展。另外,随着信息技术的发展,档案信息资源建设与开放共享向纵深发展,档案信息以数字化或网络化的形式存储和展示,档案信息资源能以更低廉、更便捷的方式实现共享和利用,也促进了档案编研客体来源的增加。二是档案客体从平面一维模态发展为立体多维模态。档案编研的发展一路受益于技术发展所带来的赋能,尤其是进入智能编研阶段以后,档案编研不再停留在汇编图文的平面一维阶段,进入融合文字、图片、音频、视频、超链接等多种形式和模态的立体多维汇编阶段。例如,中国电影资料馆利用

馆藏历史影像档案资料拍摄制作我国首部以真实影像全景式记录中华民族抗日战争历史的优秀文献纪录片《燃烧的影像》^[17],就是档案编研客体更加立体多元的生动体现。

2.1.3 编研手段实现技术与平台的转型升级

档案智能编研的发展,是编研手段不断数智化升级的过程。首先,编研手段实现了数字技术与智能技术的融合应用。智能检索、知识挖掘、自动分类等技术出现在档案编研的各环节,并相互促进,助力了档案编研向智能编研的发展进化。温州市档案馆利用文本挖掘、文本检索等技术,开发了档案资源多维检索、智能聚类等功能,自动智能产出多维、有序的档案数据集合,有助于提高档案编研素材的查找汇集效率。^[18]其次,编研手段搭载档案管理系统或平台实现升级。各类档案管理系统与管理平台为档案编研提供了丰富的编研手段。成都市档案馆依托电子档案在线管理平台建立了红色档案编研数据库,将档案管理系统与人工编研相结合并融入智慧元素,全面支持编研项目从选题确立、素材收集、全文数据分析、鉴定审核到编研成果呈现的全过程^[19];中国石油大庆油田档案馆“大庆油田组织机构沿革编纂查询系统”通过制定组织机构沿革的编研模板与数据规范,进行了档案数据化编研的有益尝试^[20]。

2.1.4 编研成果的生成与消费逻辑更为丰富

档案智能编研的发展,也是编研成果从生产到消费不断转型升级的过程。从档案资源内容挖掘来看,档案智能编研对档案文献资源的揭示从数据、信息的堆积组合转变为深层语义内容和关系多维融合。档案文献资源的汇集、关联和组织,从作者、机构等外部特征,逐步向事件、地点等内容事项和概念术语、语义关系等知识单元深入,知识的揭示从数据和信息的重组跃升到可以发现新的规律和新的知识的阶段。目前比较典型的有知识图谱和事理图谱的应用:通过实体关系抽取及构建编研知识图谱,连点成线,连线成面,形成多维度数字编研知识单元网络,从中发现编研脉络及关联相关资源^[21];在红色档案事理图谱编研中,通过构建网络化红色档案事理图谱,从人、时、地、物等角度对红色档案展开深度挖掘加工,打造人物类、地域类、专题类等多种编研成果^[22]。

在对档案资源内容挖掘结果的组织层面,档案智能编研的编研逻辑更为丰富多元。以档案编研客体不断升维进入立体多维的模态为基础,可视化

技术、AI建模等新一代数智技术被引入档案编研领域,档案编研的逻辑也从平面线性转变为多维立体。如“乾隆南巡”专题档案开发项目,从地理空间视角,对南巡线路中的景观与建筑进行从传统平面二维向三维可视化的升维阐释。^[23]

档案编研成果的消费,也从主要是获取信息需求,查阅实体的档案编研集(册)的单一消费需求和场景,发展为包括线上线下、虚实融合的涵盖艺术欣赏、娱乐消遣等多种消费需求和消费场景在内的档案编研成果消费新生态。上海图书馆举办的开放数据竞赛中,在项获奖作品中有20%的作品选择了游戏化开发方式。^[24]在智能编研场景下,也可以开展游戏化档案编研,将档案编研成果融入用户的娱乐消遣场景中,实现档案编研成果消费场景的扩展。

2.2 档案智能编研的内涵特征

档案编研进入智能编研阶段以后,除了上述变化以外,还存在一些明显的特征,将其与传统档案编研区别开来。档案智能编研实现机械化与自动化、去经验化和知识化以后,从提高工作效率、决策科学性、编研平衡性等方面针对性地解决传统档案编研存在的选题陈旧、编研周期长、编研力量薄弱、人工操作为主、主观决策等痛点问题。

2.2.1 以智能操作为基础,实现机械化与自动化

档案智能编研的智能操作首先体现在增加机械操作上。档案编研发端于史料编纂,最早可以追溯至《尚书》,通过人工对史料进行选录摘编是主要的工作模式。随着大部分档案信息实现机器可读可理解之后,档案编研不再拘泥于手工抄写和查找,通过自动识别、关键词/主题词汇聚等技术,实现内容由手工摘录向自动摘录转变,选材汇集从人工搜索向自动汇集等转变——机器自动化操作逐渐在不同的环节取代人工操作。譬如国内于2019年底发布档案行业标准《纸质档案数字复制件光学字符识别(OCR)工作规范》(DA/T 77—2019),并于2020年5月起实施。档案OCR大规模应用,加速了档案编研转录的自动化。国际上,荷兰国家档案馆启用了手写文本识别软件Transkribus进行自动识别和转录。^[25]随着OCR、语音识别(ASR)、自动标注等适用档案编研各环节的方法、技术和工具的丰富和成熟,越来越多的工具和设备将在更多的档案编研流程中得以应用,不断减少对人工操作的依赖,档案编研的自动化、机械化趋势不可逆转。

档案智能编研的智能操作其次体现在智能技术

的应用,提高编研加工的智能化水平,实现自动化。一些体例固定的档案编研形式,可以通过创建模板实现智能编研。比如,大事记、年鉴等通过制定模板,实现编研原始素材的摘录、汇集,编研内容的排版等的智能化与自动化。

2.2.2 以智慧决策为中心,实现去经验化

从档案编研选题到利用的各决策环节中,以往主要依靠主观经验,编研成果主观性强,真实客观性有待进一步考究。以选题为例,档案编研选题主要受到馆藏、服务对象的需求等影响,其中最常见的方式是依靠编研人员的经验。决策人员的个人偏好和编研经验对档案编研选题特色和质量产生重要影响。加上档案编研人员的个人偏好和编研经验难以在短时间内产生明显改变,又进一步造成档案编研选题的陈旧,这也是目前档案编研长期被诟病的地方,但又改进甚微。本研究通过网络检索,对各类档案编研优秀成果进行统计,发现优秀档案编研成果仍然集中在地区、历史事件的汇编上,与传统阶段的档案编研并无二致。虽然馆藏和团队水平一定程度上限制了编研选题的确定,但主要原因还在于其主要依靠档案编研人员的经验进行决策,而缺失了对一些新、精、趣的选题的捕捉,主观色彩浓重。依靠经验决策的现象不仅存在于档案编研选题这一环节,也存在于选材范围的确定、档案信息提炼浓缩等方面。这种依靠经验决策的现状与数字化、数据化背景下图情领域的工作现状相悖。档案编研开始依靠“让数据说话,让数据决策,让数据管理”,实现从经验判断向数据分析型的转变。例如,在利用大数据技术开展电子编研时,通过对用户利用档案的数据(包括调卷数量、利用次数、复制档案数量等数据)、用户关注点数据(包括网页浏览记录、下载记录、利用频次等数据)、业务数据(包括用户行业信息、需求信息等数据)等个性化的用户数据,进行统计分类和数据分析,建立特定用户类型的数据模型,并引以为据确定档案编研选题。^{[26][27]}档案智能编研的智慧决策,体现在通过对数据、算法、模型的综合应用,实现档案编研决策的去经验化,增加数据对档案编研决策的赋能,提高编研决策的科学性和客观性,实现智慧决策。

2.2.3 以智识服务为目标,实现知识化

近年来,信息和知识爆炸式增长、交叉融合加剧且各种智能检索工具不断涌现,图情领域将向“专、精、深”方向提供服务利用作为未来的突围方向。然而目前档案编研“编”多“研”少、重“编”

轻“研”，简单汇集的编研产品比重高。这种粗放式的信息汇集类编研成果，在专业性和知识性方面缺乏优势，难以在当前用户面临诸多选择的情况下，发挥出档案编研的应有价值并取得长足发展。因此，档案智能编研在服务方面，以提高档案编研成果的知识密度和知识价值为目标，实现档案编研的知识化。这要求档案智能编研在资源加工方面，细化资源的组织程度和加工粒度，从基于外部形式的信息汇集深入内容层面的知识挖掘、关联和揭示，转换“编”“研”比例；在编研素材组织方面，加大知识组织加工成果在原始素材中的占比，降低原始档案资料在编研素材中的占比，转换“编”“研”比例。当档案智能编研的资源加工和素材组织都增加了知识密度和知识价值，实现知识化之后，档案编研成果和编研服务的知识化就有了更多的探索空间。例如，档案智能编研可以在基本的信息汇集功效基础上，提供某一领域、事件或人物的知识性分析、梳理或预测，增加档案编研成果的附加价值；同时也可专题咨询服务、历史展览等服务功能与服务场景提供素材支持，为档案编研增加价值发挥空间。

2.3 档案智能编研的形式特征

档案智能编研实现从人工手工劳动密集向机械自动劳动密集转变。由于档案文献素材的范围之广、体量之大，在档案编研的前两个阶段中，从海量档案文献中汇集相关题材文献内容，并对之进行校对、整理、编排，再到最终编纂传播，整个过程中贯穿着大量繁杂的人工手工劳动，是典型的劳动密集类型。档案智能编研阶段的一大进步性就体现在，通过增加机械化操作、自动化操作减少档案编研生产的基础性、重复性、体力性劳动，解决人工手动编排资源耗时费力的难题^[28]，让档案编研工作从人工劳动密集向机械密集转变。

档案智能编研实现从以编为主向以研为重转变。档案智能编研阶段的一大变化，还体现在档案编研对档案资源内容的揭示从外部特征到内容特征的深入，颗粒度实现文件级—事件级—知识单元级细化。传统档案编研受限于对档案资源内容特征揭示的不足，更多的是对档案文献资源的排列重组，编研的重点停留在“编”上。档案智能编研依托智能检索、自动聚类等技术，在“编”上实现了最大限度的减负，同时知识发现、文本挖掘等新一代技术助力档案编研中“研”的比例不断上升、深度不断拓展，再加上知识经济时代，社会需求对档案编研向档案内容级开发利用的驱动，档案智能编研重心由

“编”向“研”倾斜。

档案智能编研实现从批量制作向个性定制转变。档案编研还需要走向社会化，意即档案编研工作应融入社会，在参与社会生活和服务社会各界的过程中，实现档案编研工作价值的最大化。^[29]以手工、人工为主的档案编研阶段，编研耗时耗力，基本是批量制作，一件或一类编研成果的目标客户涵盖不同行业、不同层次的档案用户。从需求满足与产品供应角度而言，其针对性、灵活性较差，档案编研工作价值的实现是有限的。档案智能编研面向编研成果受众，利用机械化、智能化程序和工具，精简编研流程、缩短编研时长，同时可以通过编研模板、用户画像等技术、算法和模型，实现档案编研选题、编排、呈现方式等的定制化、精准化。理想状态下，档案智能编研甚至能实现“一人一编研”“一事一编研”，实现从批量制作向个性定制转变。

3 档案智能编研模式构建

结合档案智能编研的全新内涵和形式特征，以及新技术环境下档案智能编研面临的社会需求现状和技术现状，本研究依据档案智能编研“机械化与自动化、去经验化、知识化”特征，坚持自动化、智能化、协同化的原则构建档案智能编研模式（见图2）。通过形成明确的、可复用的，能有效进行指导和借鉴的档案智能编研模式，为档案编研流程的重组和再造提供参考，以推动档案智能编研的规模化发展。

3.1 整合多源异构数据，打造档案智能编研数据底座

档案智能编研数据底座是档案智能编研实现的资源基础，数据底座的构建需要解决数据来源和数据治理两方面的问题，分别对应资源层和数据汇聚层。

资源层主要解决从何处获取哪些数据的问题。从编研素材角度来看，档案智能编研的编研素材范围需要进行扩充，从向编研主体自身挖掘资源转为“内外结合”利用素材。首先，编研素材资源的形态不受限制，结构化、半结构化、非结构化的档案资源都应包括在内。其次，得益于数字资源获取的便利性，应将可信的高质量网络资源也作为编研素材进行使用，例如科技文献资源、统计资源等。整体而言，档案智能编研素材资源包括内部馆藏资源和外部文献资源、网络资源、数据库资源等多种来源、多




图2 档案智能编研模式图

种模态的数据。从编研决策角度来看,档案智能编研在决策中强调去经验化,依照数据决策。因此,还需要获取用户、政策、市场等方面的数据来支撑编研选题、编研推广等环节的决策。这一部分数据主要包括用户群体数据、用户需求数据、用户行为数据等用户类数据,反映编研成果市场需求方面的反馈类数据和政策法规需求方面的政策类数据等,分别可以通过用户调研、用户画像、市场调研等工具和方法获取。

数据治理层面主要解决多源异构的档案编研数据的获取和加工问题^[30],主要包括数据获取、数据存储、数据融合、数据标引四个关键步骤。

数据获取阶段,首先要确定档案数据的评估标准,以此作为筛选数据来源的依据。例如科学数据的可发现(Findable)、可访问(Accessible)、可互操作(Interoperable)、可重用(Reusable)的FAIR管理原则。确定数据来源集合后,对于数字化的档案记录,可以通过购买、API接口访问、网络爬虫等方式批量获取;对于纸本类等传统载体中的档案记录,可以通过扫描的方式将其转化为计算机可读、可传输的数据形式。

数据存储阶段遵循数据库设计步骤,定义数据存储的结构。第一步是对需要存储的数据资源进行描述,生成数据字典;第二步是概念结构设计,描述档案数据实体之间的级联和依赖关系;第三步是逻辑

结构设计,定义数据库中关系表的结构和表间关系;第四步是明确不同用户对数据的查询、更新、删除、增加等行为的权限,通过存储过程实现用户的权限控制。

数据融合阶段需要明确档案资源的组织维度,包括外部特征维度和内部特征维度。在外部特征维度上,可以通过文字档案、图像档案、视频档案等类型对数据进行融合;在内部特征维度上,可以通过文书档案、艺术档案、专利档案等类型融合编研素材资源。每个维度都可以和其他维度的任何类目进行组合,形成描述特定类型的档案资源集合。这种细粒度的融合方式使每个档案资源既相互独立,又有机关联,方便档案数据的组织和建设。

数据标引阶段是对数据进行语义标注,目的是在内容层面建立数据之间的深度关联。人工智能技术能够准确、快速地提取大规模档案数据的特征,实现数据的批量化标引。对于文本数据,文本识别技术和自然语言处理技术可以提取档案记录中的内容信息,以便档案知识的发现与检索;对于非文本数据,计算机视觉和音频信号处理技术可以提取音像中的关键信息,分析其中包含的语义元素,实现与文本数据特征的关联。

3.2 关联跨模态语义内容,构建档案智能编研知识库

档案智能编研的要义在于通过对档案进行内

容级开发利用,将编研重心由“编”向“研”转化,关键途径是构建档案智能编研知识库。知识库是经过分类、组织和序化的相互关联的事实和知识的集合^[31],知识库中的知识类型包括属性型知识、关系型知识和事实型知识^[32]。在档案智能编研数据底座的基础上,通过知识组织工具,对档案编研资源进行分类,对知识单元进行实体识别和关系融合,并通过知识图谱等工具进行可视化展示,由此形成通用的档案智能编研知识库。但档案编研具有极强的领域特征和主题特征,在通用知识库的基础上,通过抽取、关联、表达专业领域或集成主题下全源性、分散化的知识点,构建领域或主题知识集合,形成专题知识库,更有利于支撑档案智能编研。

目前档案领域已经开始历史档案专题知识库、档案文本语境知识库、干部人事档案知识库等专题知识库探索,为档案智能编研知识库打下重要的基础。郭立鑫等^[33]将历史档案专题知识库的构建总结为“数字化、数据化、知识化、可视化”四个流程,这四个流程适用于大多数数据的专题知识库的构建。数字化、数据化流程包含于本模式的资源层和数据治理层,而知识化和可视化流程对应于档案知识库的构建。档案智能编研的多源异构数据在经数据治理层融汇治理以后,档案知识库可以按照“本体构建—实体抽取—语义连接—检索查询—知识推理”的流程进行跨模态档案资源的语义关联与可视化揭示,进而形成档案专题知识库。

3.3 基于高效便捷开发,集成档案智能编研技术与工具

要想实现档案智能编研,在数据底座和知识库的基础上,还需要集成一些关键的技术与工具来融合应用档案智能编研数据底座和知识库,以支撑档案智能编研功能的实现。从节省编研成本角度来说,灵活利用已有的插件、工具等有助于编研功能的实现,本研究将这些技术与工具概括为搜索、推荐和可视化三大类引擎,对应档案编研中的素材选择和组织加工环节。①搜索引擎,用来支撑档案编研素材的筛选与获取,为档案编研主体提供全文检索及有序呈现服务。可以使用开源的搜索引擎框架,例如ES、Solr等。②推荐引擎,用来支撑档案编研选题的推荐。通过记录用户基本信息、行为数据等,构建用户画像、用户模型等分析工具,并以此为基础向编研主体推荐可用的编研选题或编研素材。当前主流的工具包括百度分析、Google Analytics等。③可视化引擎,实现档案智能编研成果的可视化展示,可利

用ECharts、Processing等插件和工具来实现可视化功能。

3.4 面向多场景驱动,研发体系化档案智能编研功能

基于档案智能编研模式的基础工作,在档案智能编研服务层可以研发不同的智能编研功能,来满足不同场景下档案编研组织和利用的需要。

一键选题,实现面向素材和用户的“双面向”选题,充分结合可用的素材资源特征和用户特征来确定选题,在对素材资源的合理化挖掘和用户需求的最大化满足之间寻求平衡点。跨模态选材,实现档案素材跨模态搜索,可以充分应用新一代检索技术,在图像、文本、音频、视频不同模态的档案资源之间实现组合检索,减少检索次数与难度,一次性网集不同模态的所有相关素材。智能汇编,以实现汇编的丰富模板为目标,主要有两方面的含义,一是指档案编研的预设模板应根据馆藏类型、档案内容、用户需求等实现极大丰富;二是模板的适配性要足够好,这样可以针对不同的需要实现相同的编研素材能有不同的编研模板进行呈现。编研可视化,是指将档案编研素材采用可视化技术对数据、信息和知识关联进行可视化展示。编研成果智能呈现,应用知识关联、可视化技术等对档案编研成果进行多维度的呈现。多途径的智能应用,指档案智能编研成果の利用应该突破平台、设备的限制,在线上线下、大屏小屏都实现适配与应用,真实实现档案智能编研成果的传播与利用的无限制。

4 结语

本研究通过对档案智能编研的内涵特征、形式特征、编研模式进行探索,初步回答了何为档案智能编研,其为何能解决档案编研存在的痛点问题,以及该如何实现档案智能编研的问题。但要持续推进和发展档案智能编研,仍然有一些关键且具体的问题有待进一步明晰。譬如,数智时代档案智能编研的智能主要体现在数据与指令、算法、模型碰撞后的赋能,资源数据化并实现机器可操作、可计算是关键,但由于档案文献类型与内容庞杂、档案资源数据化完成度低等现状,如何使类型繁杂、数量庞大、主题广泛的档案数据达到语义理解与统一表示,解决“异构鸿沟”和“语义鸿沟”,是未来档案智能编研实现需要解决的重点与难点问题。本研究在利用通用语料库、领域/学科本体模型等领域外资源的基础

上,进行适应档案智能编研特性与需求的改造与扩建,尝试通过构建可计算可推理的档案智能数据底座、档案编研特色知识库等途径提供一个整体的解决框架,后续研究可以在档案智能编研数据底座和知识库构建的具体实施问题上继续探索。

本文系中国博士后科学基金面上资助项目“数智时代档案智能编研与知识发现研究”(2023M743832)的阶段性研究成果。

(通讯作者:寇远涛)

注释及参考文献

- [1] 何丽云. 档案编研工作的发展与思想变迁——1978~2007年档案编研工作述评[J]. 档案与建设, 2008(5): 4-6.
- [2] 杨冬荃. 大编研: 档案编研工作的新趋向和新出路[J]. 档案与史学, 1994(2): 77-79.
- [3] 周林兴, 韩永继. 由“灰”到“白”: 档案编研成果公开性转变探析[J]. 浙江档案, 2020(4): 18-20.
- [4] 邓君, 王阮. 数字人文视域下口述历史档案资源知识发现模型构建[J]. 档案学研究, 2022(1): 110-116.
- [5] 牛力, 高晨翔, 张宇峰, 等. 发现、重构与故事化: 数字人文视角下档案研究的路径与方法[J]. 中国图书馆学报, 2021(1): 88-107.
- [6] [12] [21] 牛力, 曾静怡. 数字编研: 一种全新的档案业务模式[J]. 中国档案, 2022(1): 70-71.
- [7] 邵澍赞. 档案编研出版中增强现实技术的应用场景与路径探究[J]. 档案与建设, 2022(12): 36-39.
- [8] 杨冬权. 档案编研的新样态——读《跟“档”寻踪, 打卡成都》有感[N]. 中国档案报, 2021-10-14(3).
- [9] 夏天, 钱毅. 面向知识服务的档案数据语义化重组[J]. 档案学研究, 2021(2): 36-44.
- [10] 郑金月. 数据价值: 大数据时代档案价值的新发现[J]. 浙江档案, 2015(12): 11-14.
- [11] 杨彦勋. 浅析需求导向视角下的档案编研[J]. 档案天地, 2023(6): 40-42, 27.
- [13] 郑慧, 刘思含. 人工智能与档案开发利用: 应用、愿景与进路[J]. 山西档案, 2022(5): 5-10, 28.
- [14] 沙敏. 北京市近五年档案编研成果分析[J]. 北京档案, 2018(7): 27-29.
- [15] 郑慧, 刘心怡, 杨秀翠. 广西红色档案资源体系建设研究[J]. 山西档案, 2021(5): 110-117.
- [16] 吕永明. 新时代档案馆编研工作组织实施的实践与思考——以南京市档案馆为例[J]. 档案与建设, 2023(7): 61-64.
- [17] 庞博. 影像档案编研产品的社会记忆功能浅析——以文献纪录片《燃烧的影像》为例[J]. 档案学研究, 2019(5): 78-82.
- [18] 叶亚芬, 原德巍. 基于数据化和文本检索技术的档案资源智能聚类研究[J]. 浙江档案, 2023(8): 17-19.
- [19] 张锦. 成都市档案馆建立红色档案编研专题数据库[N]. 中国档案报, 2021-12-02(2).
- [20] 祁天娇, 王强, 郭德洪. 面向知识赋能的档案数据化编研: 新逻辑及其实现[J]. 档案学通讯, 2022(1): 45-52.
- [22] [28] 孙大东, 张怡涵. 基于事理图谱的红色档案资源开发利用研究[J]. 档案学研究, 2023(5): 73-80.
- [23] 方华. 档案展览中的空间叙事探究[J]. 档案与建设, 2023(9): 53-56.
- [24] 谭雅文. 图书馆开放数据的游戏化开发路径探析[J]. 农业图书情报学报, 2022(6): 83-92.
- [25] 何露彤. 荷兰国家档案馆使用手写文本识别技术自动转录超300万页文件[EB/OL]. [2023-07-15]. http://www.zgdazxw.com.cn/news/2022-12/12/content_338787.html.
- [26] 苏一君. 应用大数据技术开展电子编研的模式探讨[J]. 中国信息化, 2023(1): 92-93.
- [27] 张文元, 张倩. 大数据技术与档案数据挖掘[J]. 档案管理, 2016(2): 33-35.
- [29] 樊如霞. 档案编研社会化论[M]. 长春: 吉林人民出版社, 2004: 27.
- [30] 刘倩倩, 刘圣婴, 刘炜. 图书情报领域大模型的应用模式和数据治理[J]. 图书馆杂志, 2023(12): 22-35.
- [31] 鄢路青. 知识库的知识表达方式探讨[J]. 情报杂志, 2003(4): 63-64.
- [32] 曹书林, 史佳欣, 侯磊, 等. 知识库问答研究进展与展望[J]. 计算机学报, 2023(3): 512-539.
- [33] 郭立鑫, 刘雨晴, 袁嘉新. 历史档案专题知识库案例分析与思考[J]. 档案管理, 2023(1): 118-120.